

Analisis Sentimen Terhadap Tayangan Televisi Berdasarkan Opini Masyarakat pada Media Sosial Twitter menggunakan Metode *K-Nearest Neighbor* dan Pembobotan Jumlah *Retweet*

Winda Estu Nurjanah¹, Rizal Setya Perdana², Mochammad Ali Fauzi³

Program Studi Teknik Informatika, Fakultas Ilmu Komputer, Universitas Brawijaya
Email: ¹windaestu@gmail.com, ²rizalespe@ub.ac.id, ³moch.ali.fauzi@ub.ac.id

Abstrak

Twitter merupakan situs *web* layanan jejaring sosial yang banyak diminati pengguna internet sebagai media komunikasi dan mendapatkan informasi. Informasi yang terdapat pada Twitter berupa pertanyaan, opini atau komentar, baik yang bersifat positif maupun negatif. Analisis sentimen merupakan salah satu cabang penelitian dari *Text Mining* yang melakukan proses klasifikasi pada dokumen teks. Metode yang digunakan adalah *K-Nearest Neighbor*, dengan menambahkan fitur pembobotan jumlah *retweet* (non-tekstual). Pembobotan tekstual hasil dari klasifikasi *K-Nearest Neighbor* dan pembobotan non-tekstual dari pembobotan jumlah *retweet* akan digabungkan menggunakan nilai konstanta tertentu (α dan β) untuk menghasilkan sentimen positif dan negatif. Data yang digunakan berupa opini masyarakat terhadap tayangan televisi pada twitter sejumlah 400. Dari hasil pengujian akurasi menggunakan pembobotan tekstual diperoleh 82,50%, menggunakan pembobotan non-tekstual 60%, dan menggunakan penggabungan keduanya 83,33% dengan nilai $k=3$ dan konstanta perkalian yang tepat $\alpha=0,8$ dan $\beta=0,2$.

Kata Kunci: analisis sentimen, Twitter, *K-Nearest Neighbor*, pembobotan jumlah *Retweet*.

Abstract

Twitter is a social media that attracts many internet users as a media for communication and getting information. The information covered on Twitter in the form of questions, opinions or comments, whether it is positive or negative. Sentiment analysis is a part of research from *Text Mining* that conducted the classification process on text documents. *K-Nearest Neighbor* was used as method of this research, by adding the quality of *retweet* (non-textual). The result of textual quality of the *K-Nearest Neighbor* classification and the non-textual quality from the sum of *retweets* would be combined using certain constants (α and β) to generate positive and negative sentiments. The data was used in the form of public opinion on the television show on twitter showed 400. From the test results of accuracy using non-textual quality obtained 82.50%, using 60% non-textual quality, and use the combination of both was 83.33% with the score $k=3$ and the exact multiplication constant $\alpha=0,8$ and $\beta=0.2$.

Keywords: sentiment analysis, Twitter, *K-Nearest Neighbor*, weighting the number of *Retweets*.

1. PENDAHULUAN

Televisi merupakan salah satu media elektronik yang menjadi hiburan dan sumber informasi bagi pemirsa tayangan televisi. Penilaian untuk tayangan televisi dapat dilihat melalui *rating* atau program apa saja yang paling banyak disaksikan oleh masyarakat. Stasiun televisi menggunakan *Nielsen Audience Measurement* sebagai jasa penelitian peringkat program (*rating*), dengan melakukan perhitungan *rating* dan *share* televisi

(Fachruddin, 2016). Hasil dari perhitungan tersebut, akan mengeluarkan laporan rutin setiap hari untuk masing-masing stasiun televisi mengenai program apa saja yang menjadi unggulan dan tidak diunggulkan lagi (Fachruddin, 2016). *Nielsen Audience Measurement* merupakan perusahaan yang menyelenggarakan pengukuran kepemirsaaan televisi atau disebut dengan *Television Audience Measurement* (TAM).

Nilai *rating* sangat penting untuk bertahannya suatu tayangan televisi, namun

tidak menjamin tayangan televisi tersebut memiliki kualitas yang tinggi (Tiara, Sabariah, & Effendy, 2015). Sering kali pemirsa tayangan televisi memberikan opini atau komentar terhadap tayangan televisi melalui media sosial salah satunya Twitter. Opini tersebut berupa *tweet* yang nantinya akan menjadi sebuah berita yang tersebar pada *timeline* Twitter. Opini masyarakat pada Twitter terhadap tayangan televisi memiliki peranan yang penting, karena dapat digunakan untuk melakukan analisis sentimen dalam memprediksi penilaian masyarakat terhadap suatu tayangan televisi, apakah bersifat positif atau negatif.

Analisis sentimen merupakan bidang studi yang menganalisis pendapat, sentimen, penilaian, evaluasi, sikap, dan emosi seseorang terkait suatu topik, layanan, produk, individu, organisasi, atau kegiatan tertentu (Liu, 2012). Analisis sentimen dilakukan untuk menentukan apakah opini atau komentar terhadap suatu permasalahan, memiliki kecenderungan positif atau negatif dan dapat dijadikan sebagai acuan dalam meningkatkan suatu pelayanan, ataupun meningkatkan kualitas produk.

Algoritme yang digunakan untuk proses klasifikasi yaitu K-Nearest Neighbor dan dilakukan penambahan fitur pembobotan jumlah *retweet*. Algoritme tersebut dipilih karena dari penelitian sebelumnya yang dilakukan oleh Samuel, Delima dan Rachmat (2014), membahas tentang klasifikasi subtopik berita, menunjukkan akurasi yang baik, dengan nilai $k=3$, menunjukkan hasil persentase 88,29% (Samuel, Delima, & Rachmat, 2014). Penelitian lainnya dilakukan oleh Perdana dan Pinandito (2016), membahas tentang kombinasi *Likes-Retweet* dan *Näive Bayes Classifier* dalam Twitter untuk proses analisis sentimen. Kombinasi kedua fitur tersebut menghasilkan nilai *F-measure* sebesar 0,838 (Perdana & Pinandito, 2017). Penggabungan algoritme K-Nearest Neighbor dan penambahan fitur pembobotan jumlah *retweet* diharapkan mampu meningkatkan hasil akurasi dan dapat melakukan klasifikasi dengan hasil yang tepat, sehingga hasil keluaran sistem mampu menjadi acuan serta pertimbangan bagi pemirsa tayangan televisi dan dalam memilih tayangan yang banyak disukai oleh masyarakat umum.

2. METODE USULAN

Tahapan proses pada sistem analisis sentimen terhadap tayangan televisi berdasarkan

opini masyarakat pada media sosial Twitter menggunakan metode K-Nearest Neighbor dan pembobotan jumlah *Retweet* diawali dengan proses menghitung pembobotan tekstual, dimulai dari praproses, yang mana dalam proses ini ada beberapa proses yaitu tokenisasi, *cleansing*, *case folding*, filterisasi dan *stemming*. Tahapan selanjutnya yaitu pembobotan kata, dalam proses ini ada beberapa proses yaitu TF, DF, Wtf, IDF, dan TF-IDF. Setelah dilakukan proses pembobotan kata, maka akan dihitung tingkat kemiripan dokumen menggunakan *cosine similarity*, kemudian masuk pada proses klasifikasi teks menggunakan metode K-Nearest Neighbor. Tahap selanjutnya dilakukan pembobotan jumlah *Retweet* (non-tekstual). Pada tahapan ini, jumlah *Retweet* pada dokumen *tweet* akan diberikan bobot sesuai dengan jumlah *retweet* yang ada pada dokumen tersebut dengan proses normalisasi *min-max*. Normalisasi jumlah *retweet* dilakukan untuk setiap jumlah *retweet* pada data uji yang dibandingkan dengan jumlah *retweet* pada data latih tetangganya. Selanjutnya hasil pembobotan tekstual akan digabungkan dengan pembobotan jumlah *retweet* (non-tekstual) yang sebelumnya telah dilakukan normalisasi *min-max*. Hasil dari penggabungan tersebut akan menghasilkan suatu nilai, sehingga dapat diketahui dokumen yang telah dilakukan proses klasifikasi bernilai positif atau negatif. Alur dari proses sistem dapat ditampilkan dalam Gambar 1.

2.1. Pembobotan Kata

Pembobotan kata (*term*) bertujuan untuk memberikan bobot pada setiap kata (*term*) yang terdapat pada dokumen teks yang akan diproses. Tahapan pada pembobotan kata yaitu sebagai berikut:

1. Term Frequency (TF)

Term Frequency merupakan frekuensi kemunculan kata pada suatu dokumen teks. *Term Frequency* ($tf_{t,d}$) didefinisikan jumlah kemunculan term t pada dokumen d . Persamaan dari *Term Frequency* ($tf_{t,d}$) ditunjukkan pada Persamaan 1.

$$W_{tf_{t,d}} = \begin{cases} 1 + \log_{10} tf_{t,d}, & \text{if } tf_{t,d} > 0 \\ 0, & \text{lainnya} \end{cases} \quad (1)$$

Keterangan :

$tf_{t,d}$ adalah jumlah kemunculan *term* t pada dokumen d .

2. Document Frequency (DF)

Document Frequency merupakan kata-kata yang banyak terdapat pada dokumen, kata tersebut tidak informatif, seperti kata dan, di, atau, bisa, merupakan.

3. Invers Document Frequency (IDF)

Invers Document Frequency merupakan frekuensi kemunculan term pada keseluruhan dokumen teks. *Term* yang jarang muncul pada keseluruhan dokumen teks memiliki nilai *Invers Document Frequency* lebih besar dibandingkan dengan *term* yang sering muncul (Rahmawati, Sihwi, & Suryanti, 2014). Persamaan dari *Invers Document Frequency* (IDF) ditunjukkan pada Persamaan 2.

$$idf_t = \log_{10} \left(\frac{N}{df_{(t)}} \right) \quad (2)$$

Dengan :

N adalah jumlah dokumen teks.

$df_{(t)}$ adalah jumlah dokumen yang mengandung *term t*.

4. Term Frequency - Invers Document Frequency (TF-IDF)

Nilai tf-idf dari sebuah kata merupakan kombinasi dari nilai tf dan nilai idf dalam perhitungan bobot. Persamaan dari TF-IDF ditunjukkan pada Persamaan 3.

$$W_{t,d} = W_{tf,t,d} \times idf_t \quad (3)$$

Keterangan :

$W_{tf,t,d}$ adalah *Term Frequency*.

idf_t adalah *Invers Document Frequency*.

2.2. K-Nearest Neighbor

K-Nearest Neighbor (KNN) adalah salah satu metode paling sederhana untuk memecahkan masalah klasifikasi (Adeniyi, Wei, & Yongquan, 2016). Algoritme ini sering digunakan untuk klasifikasi teks dan data (Samuel, Delima, & Rachmat, 2014). Pada metode ini dilakukan klasifikasi terhadap obyek berdasarkan data yang jaraknya paling dekat dengan obyek tersebut (Hardiyanto & Rahutomo, 2016).

Klasifikasi teks menggunakan metode KNN akan menghasilkan nilai yang lebih optimal jika menggunakan rumus *cosine similarity* untuk pembobotan tiap-tiap kata pada dokumen teks yang akan diproses. Sebelum menghitung nilai

cosine similarity, harus melakukan tahapan dalam proses pembobotan kata yaitu tf, df, idf, tf-idf yang terdapat pada rumus persamaan 1 sampai persamaan 3. Setelah pembobotan kata selesai, selanjutnya yaitu menghitung kemiripan antar dokumen menggunakan rumus *cosine similarity*.

Persamaan dari *cosine similarity* ditunjukkan pada Persamaan 4.

$$CosSim(q, d_j) = \frac{d_j \cdot q}{|d_j| \cdot |q|} = \frac{\sum_{i=1}^t (w_{ij} \cdot w_{iq})}{\sqrt{\sum_{i=1}^t w_{ij}^2} \cdot \sqrt{\sum_{i=1}^t w_{iq}^2}} \quad (4)$$

Keterangan:

$CosSim(q, d_j)$: Nilai kemiripan antara dokumen uji (q) dengan dokumen latih ke j (d_j)

t : Jumlah term (kata)

d : dokumen

q : kata kunci (query)

w_{ij} : Bobot term (kata) ke i pada dok. latih j

w_{iq} : Bobot term (kata) ke i pada dok. uji q

2.3. Pembobotan Jumlah Retweet (Non-Tekstual)

Retweet merupakan salah satu fitur yang ada pada media sosial Twitter. Fitur ini berfungsi untuk membagikan atau menyebarkan *tweet* dari pengguna Twitter lain atau mengacu pada *tweet* yang didistribusikan kembali. Pembobotan jumlah *retweet* ini bertujuan untuk menambah nilai positif pada *tweet* yang memiliki banyak *retweet*, sehingga dapat mempengaruhi nilai sentimen pada *tweet* tersebut, dan dapat diketahui dengan jelas *tweet* apa saja yang memiliki nilai sentimen positif. Jumlah angka *retweet* dapat memperkuat *tweet* memiliki sentimen positif (Perdana & Pinandito, 2017). Jumlah *retweet* merupakan data non-tekstual yang akan dilakukan setelah klasifikasi KNN selesai dilakukan. Bobot yang akan diberikan, berdasarkan jumlah *retweet* yang terdapat pada dokumen *tweet* tersebut. Jumlah *retweet* tersebut akan dilakukan normalisasi menggunakan *min-max*, agar bobot yang diberikan seimbang dengan bobot teks hasil klasifikasi KNN.

2.4. Normalisasi Min-max

Normalisasi *Min-max* merupakan proses transformasi yang mana atribut berupa angka akan diskala ke dalam suatu ukuran yang lebih kecil, seperti antara -1 sampai 1 atau 0 sampai 1

(Junaedi, Budianto, Maryati, & Melani, 2011).

Proses normalisasi tersebut akan memudahkan penelitian, karena data asli akan diganti ke dalam bentuk lain dengan skala yang sama (Maulana, Saepudin, & Rohmawati, 21016). Metode *Min-max* merupakan metode yang paling sederhana dalam proses transformasi linier terhadap data asli. Setelah dilakukan proses normalisasi *Min-max*, dapat diperoleh keseimbangan nilai perbandingan antara nilai sebelum dilakukan proses normalisasi dan nilai setelah dilakukan proses normalisasi (Wirawan & Eksistyanto, 2015). Persamaan normalisasi *Min-max* dapat dilihat pada Persamaan 5.

$$v'_i = \frac{v_i - \min_A}{\max_A - \min_A} (new_max_A - new_min_A) + new_min_A \quad (5)$$

Keterangan :

v'_i : Nilai data yang baru dari hasil normalisasi min-max.

v_i : Nilai data yang akan dilakukan normalisasi.

\max_A : Nilai maksimum data.

\min_A : Nilai minimum data.

new_max_A : Nilai maksimum yang diharapkan dari proses normalisasi (0,9).

new_min_A : Nilai minimum yang diharapkan dari proses normalisasi (0,1).

2.5. Penggabungan Pembobotan Tekstual dan Non-Tekstual

Penggabungan pembobotan tekstual dan non-tekstual merupakan tahapan akhir untuk mengetahui sentimen positif atau negatif pada proses klasifikasi yang melakukan kombinasi antara pembobotan tekstual dan non-tekstual (Perdana & Pinandito, 2017). Penggabungan dilakukan pada pembobotan tekstual dan pembobotan non-tekstual menggunakan nilai konstanta tertentu sebagai nilai pembanding dalam menggunakan pembobotan tekstual dan non-tekstual. Rumus untuk penggabungan pembobotan tekstual dan non-tekstual dapat dilihat pada Persamaan 6 (Perdana & Pinandito, 2017).

$$PenggabC_j = (\alpha \times TeksC_j) + (\beta \times NonTeksC_j) \quad (6)$$

Keterangan :

α : Konstanta pengali sebagai pembanding untuk pembobotan tekstual.

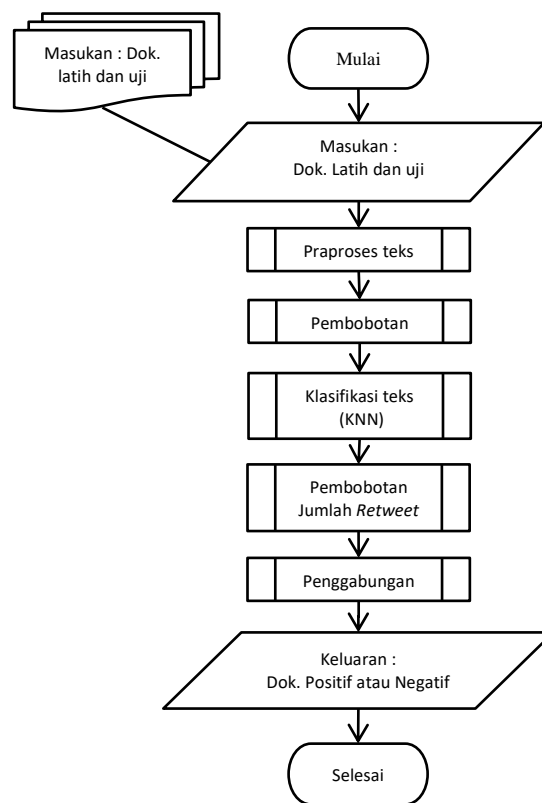
$TeksC_j$: Nilai *cosine similarity* hasil klasifikasi KNN.

β : Konstanta pengali sebagai

pembanding untuk pembobotan non-tekstual.

$NonTeksC_j$: Nilai pembobotan jumlah *Retweet*.

Gambar 1. merupakan diagram alur dari sistem yang dibuat.



Gambar 1. Diagram Alur Sistem

3. HASIL DAN PEMBAHASAN

3.1. Pengujian Pengaruh Nilai k

Pengujian pengaruh nilai k dilakukan untuk mengetahui nilai k optimal untuk melakukan proses klasifikasi KNN terhadap hasil akurasi sistem. Pada pengujian ini menggunakan nilai k yang bervariasi. Setiap nilai k yang digunakan, akan menjadi parameter dari pengujian, sehingga dapat diketahui pengaruh nilai k tersebut terhadap akurasi sistem.

Pada pengujian pengaruh nilai k , nilai konstanta α dan β yang digunakan masing-masing 0,5. Uji coba perhitungan nilai k dilakukan sebanyak 20 kali sampai sejumlah data latih yaitu 280. Hasil dari pengujian pengaruh nilai k terdapat pada Tabel 1.

Tabel 1. Pengujian Nilai k

No	Nilai k	Accuracy	Precision	Recall	F-Measure
1	2	70%	62,76%	98,33%	76,62%
2	3	80,83%	72,28%	100%	83,91%
3	4	72,50%	64,51%	100%	78,43%
4	5	71,66%	63,82%	100%	77,92%
5	6	72,50%	64,51%	100%	78,43%
6	7	71,66%	63,82%	100%	77,92%
7	8	73,33%	65,21%	100%	78,94%
8	9	74,16%	65,93%	100%	79,47%
9	10	69,16%	61,85%	100%	76,43%
10	15	65,83%	59,40%	100%	74,53%
11	20	62,50%	57,14%	100%	72,72%
12	25	62,50%	57,14%	100%	72,72%
13	30	61,66%	56,60%	100%	72,28%
14	35	55%	52,63%	100%	68,96%
15	40	52,50%	51,28%	100%	67,79%
16	45	51,66%	50,84%	100%	67,41%
17	50	51,66%	50,84%	100%	67,41%
18	100	50%	50%	100%	66,67%
19	200	50%	50%	100%	66,67%
20	280	50%	50%	100%	66,67%

Berdasarkan pada Tabel 1, maka dapat dilakukan analisis :

1. Pada pengujian pengaruh nilai k menunjukkan bahwa nilai k optimal untuk melakukan proses klasifikasi KNN adalah $k=3$, dengan tingkat akurasi mencapai 80,83%, *precision* mencapai 72,28%, *recall* mencapai 100%, dan *f-measure* mencapai 83,91%. Sedangkan nilai k yang menghasilkan akurasi paling rendah yaitu $k=100$, $k=200$, dan $k=280$, karena jumlah ketetangaan yang terlalu banyak sehingga mengurangi tingkat akurasi.
2. Nilai *recall* pada nilai $k=3$ sampai $k=280$ mencapai nilai 100% karena hasil keluaran sistem tidak memiliki nilai *false negatif*. Sedangkan untuk nilai *precision* pada semua nilai k yang diuji memiliki nilai yang berbeda-beda. Semakin banyak nilai *false positif* pada hasil keluaran sistem, maka semakin kecil nilai *precision* yang dihasilkan, dan semakin banyak nilai *false negatif* pada hasil keluaran sistem, maka semakin kecil nilai *recall* yang dihasilkan.
3. Pada pengujian ini, nilai k yang diuji tidak memperhatikan jumlah ganjil maupun genap, karena semua tetangga dari data uji sejumlah k , akan dikelompokkan berdasarkan kategori positif dan negatif, kemudian nilai kemiripannya yaitu hasil penggabungan bobot tekstual dan non-tekstual akan dijumlahkan, dan dibandingkan nilai mana yang paling besar, apakah nilai untuk kategori positif atau negatif.

3.2. Pengujian Pengaruh Pembobotan Retweet

Pada pengujian pengaruh pembobotan jumlah *Retweet*, nilai konstanta α dan β akan dilakukan perbandingan sebanyak 11 kali dengan jarak 0-1 atau dengan ketentuan $\beta=(1-\alpha)$. Konstanta α merupakan konstanta yang akan dikali dengan pembobotan teks, sedangkan konstanta β merupakan konstanta yang akan dikali dengan pembobotan jumlah *retweet*. Sehingga, jika nilai konstanta $\alpha=0$, maka proses klasifikasi hanya menggunakan pembobotan jumlah *retweet* saja. Sedangkan jika nilai konstanta $\beta=0$, maka proses klasifikasi hanya menggunakan pembobotan teks saja. Nilai k yang digunakan adalah nilai k optimal, hasil dari pengujian yang telah dilakukan sebelumnya yaitu $k=3$. Hasil dari pengujian pengaruh pembobotan jumlah *retweet* terdapat pada Tabel 2.

Tabel 2. Pengujian Pengaruh Pembobotan Jumlah Retweet

No	Konstant		Accuracy	Precision	Recall	F-Measure
	α	β (1- α)				
1.	1	0	82,50%	77,46%	91,66%	83,96%
2.	0,9	0,1	83,33%	77,02%	95%	85,07%
3.	0,8	0,2	83,33%	76,31%	96,67%	85,29%
4.	0,7	0,3	82,50%	74,07%	100%	85,10%
5.	0,6	0,4	82,50%	74,07%	100%	85,10%
6.	0,5	0,5	80,83%	72,28%	100%	83,91%
7.	0,4	0,6	75,83%	67,41%	100%	80,53%
8.	0,3	0,7	64,16%	58,25%	100%	73,61%
9.	0,2	0,8	61,66%	56,60%	100%	72,28%
10.	0,1	0,9	60,83%	56,07%	100%	71,85%
11.	0	1	60%	55,56%	100%	71,42%

Berdasarkan pada Tabel 2, maka dapat dilakukan analisis :

1. Pada pengujian pengaruh pembobotan jumlah *retweet* menunjukkan bahwa nilai α dan β yang optimal sebagai konstanta perkalian untuk melakukan proses penggabungan pembobotan tekstual dan non-tekstual yaitu $\alpha=0,8$ dan $\beta=0,2$ menghasilkan tingkat akurasi yang tinggi mencapai 83,33%, *precision* mencapai

76,31%, nilai *recall* tidak mencapai 100%, hanya mencapai 96,67%, dan *f-measure* mencapai 85,29%.

2. Pembobotan jumlah *retweet* terbukti memiliki pengaruh pada hasil klasifikasi dan tingkat akurasi sistem dengan nilai konstanta α dan β yang tepat yaitu perbandingan antara keduanya harus lebih tinggi nilai konstanta α daripada konstanta β . Kondisi tersebut membuktikan bahwa pembobotan teks lebih berperan daripada pembobotan jumlah *retweet*. Penambahan pembobotan jumlah *retweet* dapat meningkatkan nilai *accuracy*, *precision*, *recall*, dan *f-measure* meskipun hasilnya tidak terlalu signifikan.

3.3. Pengujian Akurasi Sistem

Pada pengujian akurasi sistem ini perbandingan data latih dan data uji yang digunakan yaitu 70% untuk data latih dan 30% untuk data uji (Faradhillah, Kusumawardani, & Hafidz, 2016). Jumlah data latih dan data uji yang digunakan yaitu 280 dan 120 (Samuel, Delima, & Rachmat, 2014). Kemudian pada pengujian ini akan membandingkan tingkat akurasi sistem hanya menggunakan pembobotan tekstual, hanya menggunakan pembobotan non-tekstual, dan penggabungan pembobotan tekstual dan non-tekstual. Nilai k yang digunakan untuk melakukan pengujian akurasi sistem adalah $k=3$, dan nilai konstanta yang digunakan $\alpha=0,8$ dan $\beta=0,2$. Parameter pengujian yang digunakan yaitu *Accuracy*, *Precision*, *Recall*, dan *F-Measure*. *Confusion Matrix* dan hasil dari pengujian akurasi sistem terdapat pada Tabel 3 dan Tabel 4.


Tabel 3. *Confusion Matrix* Pengujian Akurasi Sistem

	Pembobotan Tekstual	Pembobotan Non-Tekstual	Penggabungan Pembobotan Tekstual dan Non-Tekstual
True Positif	55	60	58
False Positif	16	48	18
True Negatif	44	12	42
False Negatif	5	0	2

Tabel 4. Hasil Pengujian Akurasi Sistem

	Pembobotan Tekstual	Pembobotan Non-Tekstual	Penggabungan Pembobotan Tekstual dan Non-Tekstual
Accuracy	82,50%	60%	83,33%
Precision	77,46%	55,55%	76,31%
Recall	91,66%	100%	96,66%
F-Measure	83,96%	71,42%	85,29%

Dari hasil pengujian tersebut dapat dilihat grafik pengujian akurasi sistem yang ditampilkan dalam Gambar 2.



Gambar 2. Grafik Pengujian Akurasi Sistem

Berdasarkan pada Gambar 2, maka dapat dilakukan analisis :

1. Pada pengujian yang dilakukan hanya menggunakan pembobotan tekstual saja, menghasilkan nilai *accuracy* mencapai 82,50%. Tingkat akurasi cukup tinggi meskipun tidak ditambahkan pembobotan non-tekstual. Namun pada pengujian ini terdapat false negatif sebanyak 5. *False negatif* merupakan dokumen uji yang seharusnya masuk pada kategori positif, namun hasil analisis sistem menghasilkan keluaran negatif. Agar jumlah *false negatif* berkurang, sebaiknya ditambahkan pembobotan non-tekstual agar memperkuat nilai positif pada dokumen uji tersebut, sehingga dapat meningkatkan nilai akurasi.
2. Pada pengujian yang dilakukan hanya menggunakan pembobotan non-tekstual

saja, menghasilkan tingkat akurasi paling rendah yaitu 60%. Hal tersebut terjadi karena pembobotan tekstual tidak dilakukan perhitungan untuk proses penggabungan, sehingga dokumen uji yang tidak memiliki jumlah *Retweet* akan diberikan bobot 0,1, karena pada normalisasi jumlah *Retweet*, nilai minimum diberikan bobot 0,1. Hal tersebut menghasilkan jumlah *false positif* sebanyak 16, yang mengakibatkan tingkat akurasi yang rendah. Nilai *recall* ketika menggunakan pembobotan non-tekstual dapat mencapai 100% karena tidak terdapat *false negative*, sehingga nilai *recall* dapat mencapai 100%.

3. Pada pengujian yang dilakukan penggabungan pembobotan tekstual dan non-tekstual dengan nilai konstanta $\alpha=0,8$ dan $\beta=0,2$ memperoleh nilai *accuracy* paling tinggi diantara pembobotan tekstual dan non-tekstual saja meskipun selisihnya tidak terlalu signifikan yaitu mencapai 83,33%. Kondisi tersebut terjadi karena penambahan pembobotan non-tekstual yang digabungkan dengan pembobotan tekstual dapat memperkuat nilai positif pada dokumen uji, yang mengakibatkan jumlah *false negatif* berkurang, sehingga dapat meningkatkan nilai akurasi. Hal tersebut menunjukkan bahwa penambahan pembobotan non-tekstual dapat mempengaruhi tingkat akurasi dari sistem.

4. KESIMPULAN

Dari hasil pengujian dan analisis yang telah dilakukan sebelumnya, maka dapat diambil suatu kesimpulan, yaitu :

1. Metode KNN dan pembobotan jumlah *retweet* dapat diterapkan pada analisis sentimen terhadap tayangan televisi berdasarkan opini masyarakat pada media sosial Twitter. Tahapan proses yang dilakukan yaitu pembobotan tekstual, pembobotan jumlah *retweet* (non-tekstual) yang dinormalisasi *Min-max*, kemudian penggabungan antara keduanya sehingga dapat diketahui dokumen yang telah dilakukan proses klasifikasi bernilai positif atau negatif.
2. Nilai k optimal untuk melakukan proses klasifikasi KNN adalah $k=3$, dengan tingkat akurasi mencapai 80,83%, *precision* mencapai 72,28%, *recall* mencapai 100%,

dan *f-measure* mencapai 83,91%.

3. Pengujian nilai konstanta α dan β mendapatnya nilai α dan β yang optimal yaitu $\alpha=0,8$ dan $\beta=0,2$ dengan menggunakan nilai $k=3$, menghasilkan tingkat akurasi mencapai 83,33%, *precision* mencapai 76,31%, nilai *recall* mencapai 96,67%, dan *f-measure* mencapai 85,29%. Nilai konstanta α dan β yang tepat yaitu perbandingan antara keduanya harus lebih tinggi nilai konstanta α daripada konstanta β . Kondisi tersebut membuktikan bahwa pembobotan teks lebih berperan daripada pembobotan jumlah *Retweet*. Penambahan pembobotan jumlah *Retweet* dapat meningkatkan nilai *accuracy*, *precision*, *recall*, dan *f-measure* meskipun hasilnya tidak terlalu signifikan.
4. Tingkat akurasi ketika menggunakan pembobotan tekstual mencapai 82,50%, ketika menggunakan pembobotan non-tekstual mencapai 60%, sedangkan ketika menggunakan penggabungan keduanya mencapai 83,33%. Nilai k yang digunakan yaitu $k = 3$ yang merupakan k optimal, dan konstanta $\alpha=0,8$ dan $\beta=0,2$. Dapat disimpulkan bahwa penggabungan pembobotan tekstual dan pembobotan non-tekstual dapat meningkatkan akurasi sistem.

DAFTAR PUSTAKA

- Adeniyi, D., Wei, Y., & Yongquan, Y. (2016). Automated web usage data mining and recommendation system using. *Applied Computing and Informatics*, 12, 90–108.
- Fachruddin, A. (2016). *Manajemen Pertelevisian Indonesia Modern*. Yogyakarta, Jawa Tengah.
- Faradhillah, N. T., Kusumawardani, R. P., & Hafidz, I. (2016). Eksperimen Sistem Klasifikasi Analisa Sentimen Twitter Pada Akun Resmi Pemerintah Kota Surabaya Berbasis Pembelajaran Mesin. *Seminar Nasional Sistem Informasi Indonesia*.
- Hardiyanto, E., & Rahutomo, F. (2016). Studi Awal Klasifikasi Artikel Wikipedia Bahasa Indonesia Dengan Menggunakan Metoda K-Nearest Neighbor. *Seminar Nasional Terapan Riset Inovatif Semarang*. Semarang.

- Junaedi, H., Budianto, H., Maryati, I., & Melani, Y. (2011). Data Transformation pada Data Mining. Surabaya: IdeaTech2011.
- Liu, B. (2012). Sentiment Analysis And Opinion Mining. Diakses pada tanggal : 27 Februari 2017, Tersedia di <https://www.cs.uic.edu/~liub/FBS/SentimentAnalysis-and-OpinionMining.pdf>
- Maulana, M. F., Saepudin, D., & Rohmawati, A. A. (2016). Pemodelan Sistem Dinamika Antara Suku Bunga Bank Indonesia, Kurs Dolar Terhadap Rupiah, dan Inflasi dengan Algoritma Genetika dan Runge Kutta. Bandung: Universitas Telkom.
- Perdana, R. S., & Pinandito, A. (2017). Combining Likes-Retweet Analysis and Naive Bayes Classifier Within Twitter for Sentiment Analysis. International Conference On Communication And Computer Engineering. Penang, Malaysia: Journal of Telecommunication, Eletronic And Computer Engineering (JTEC).
- Samuel, Y., Delima, R., & Rachmat, A. (2014). Implementasi Metode K-Nearest Neighbor dengan Decision Rule untuk Klasifikasi Subtopik Berita. 10, hal. 1-15.
- Tiara, Sabariah, M. K., & Effendy, V. (2015). Analisis Sentimen pada Twitter untuk Menilai Performansi Program Televisi dengan Kombinasi Metode Lexicon-Based dan Support Vector Machine. 3rd International Conference on Information and Communication Technology (ICoICT) (hal. 386-390). Bandung: Universitas Telkom.